

AgentSPEX: An Agent Specification and EXecution Language

Pengcheng Wang[✉], Jerry Huang[✉], Jiarui Yao[✉], Rui Pan[✉], Peizhi Niu[✉],




Figure 1: An overview of the AgentSPEX Architecture.




Figure 3: Visual editor interface for a deep research agent implemented with AgentSPEX.

Agent	Model	Domain	Score
SciBench (Wang et al., 2024a)			
CoT	GPT-5	Science	85.92%
ReAct	GPT-5	Science	87.79%
AgentSPEX (Ours)	GPT-5	Science	90.61%
StemEZ (Wang et al., 2024b)			
CoT	GPT-5	Science	82.87%
ReAct	GPT-5	Science	84.72%
AgentSPEX (Ours)	GPT-5	Science	86.57%

YAML定义Agent工作流

今天给大家带来关于大模型智能体框架的新研究，他们把agent的工作流直接用YAML“编程”了。

🔑 关键方法

- 1 声明式YAML规范：把所有agent的推理、工具调用、分支循环等控制流，直接写成结构化的YAML配置文件，不再需要Python代码硬编码。
- 2 显式状态与上下文管理：每一步的输入输出变量都用{{variable}}模板显式控制，精确决定agent每步能看到什么历史信息，避免“上下文腐烂”导致的性能衰减。
- 3 持久化执行引擎：配备Docker沙箱环境、断点检查点、轨迹回放等机制，支持长任务的中断恢复和单步调试。

💡 核心创新

- 1 执行与规范分离：把agent的“逻辑规约”和“执行运行时”解耦，同一份YAML workflow可在不同模型上稳定跑，模型升级时代码几乎不用改。
- 2 完整耐久性体系：提供checkpoint、选择性trace replay等机制，改中间某一步prompt时，可以只重放下游步骤而不重跑整个流程。
- 3 可视化双向编辑：拖拽节点修改流程图，同步更新YAML代码，反之亦然，极大降低非程序员门槛。

实验效果

- ✓ 7个基准全面领先：在化学、数学、软件工程等7个benchmark上全部SOTA。
- ✓ SWE-Bench Verified达77.1%，两个Claude版本间只差0.2%，而对比框架最高掉6.8%。
- ✓ AIME 2025满分，ELAIPBench比ReAct基线高出6.5个百分点。

论文：AgentSPEX: An Agent SPecification and EXecution Language

欢迎投稿！欢迎合作！

收录于  agent

北京 4月28日 10:32