



底座不是工具清单，是让一切能协同的骨架。

一次性讲完 —— 五层主干 + 四条横向：

L1 基础设施：GPU 池 + K8s + RDMA + 分布式存储。GPU 利用率决定 TCO。

L2 推理平台：模型仓库、推理引擎、网关、加速、弹性微调。把模型变成高可用服务。

L3 数据管理平台：接入、标注、向量库、知识图谱、治理。训练与检索的共同地基。

L4 应用开发平台：Agent、工作流、RAG、Prompt、MCP。AI 应用的生产力层。

L5 应用层：客服、知识助手、业务 Agent、垂直 Copilot。真正产生价值的地方。

横向四条 —— 安全合规、可观测性、统一认证、计量计费 —— Day 1 就得做，后补必重构。

最容易踩的坑：以为底座越全越好。真相是 —— 跑不出应用的底座是摆设。先用标杆场景打样，再谈规模化。

作者提示: 个人观点，仅供参考

四川 4月22日 21:28 已修改 ①