

工程 Harness 是怎么实现的？

Harness 就像一个“严格的老师”，用一套自动化的方法来测试大模型，保证它的质量和稳定性。

简单说，Harness 就是让模型在各种题目上考试，自动打分，发现问题！

1. 准备测试题（构建数据集）

工程师会准备很多高质量的“考题”，覆盖不同的能力和场景。

- 通用能力**
如：知识问答、推理、数学
- 专业能力**
如：代码、文档理解
- 对话能力**
如：多轮对话、指令遵循
- 安全与合规**
如：有害内容、隐私、偏见

示例题目

问题：
小明有 5 个苹果，
又买了 3 个，
他现在有几个苹果？

标准答案：8

每道题都有“标准答案”或“评判规则”。

2 运行模型（自动化执行）

Harness 会自动把每道题发给模型，收集模型的回答。



可以同时在不同版本、不同参数配置的模型上运行，保证公平、可重复。

3 自动评分（评估指标）

Harness 根据标准答案或规则，自动给模型打分。

- 准确匹配**
判断答案是否正确
- 相似度匹配**
答案语义是否相近
(如：使用文本相似度)
- 规则校验**
是否符合格式、长度、安全要求等
- 大模型裁判**
让另一个强模型当“裁判”，给出评价（如：好/一般/差）

题目 1 ☒

题目 2 ☒

题目 3 ☐

题目 4 ...

不同类型的题目使用合适的评分方法，综合计算得分。

4 结果分析（发现问题）

Harness 会把结果统计、可视化，帮助工程师发现问题。



快速看到：哪些能力变强了，哪些变弱了；
哪些题目错得多；不同版本之间的差异。

5 持续集成（CI/CD 自动化）

Harness 会集成到研发流程中，模型有任何改动都会自动跑全套测试。



好处：

- ✓ 减少人工测试工作量
- ✓ 结果客观、稳定、可复现
- ✓ 快速发现问题，提升质量
- ✓ 支持大规模对比和回归测试

6 可扩展与定制化

工程师可以根据业务需求，灵活扩展 Harness。

- 自定义数据集
加入自己的题目
- 自定义评估规则
设计专属的打分逻辑
- VS
多模型对比
比较不同模型表现
- 多语言支持
测试多种语言能力

总结：

Harness 就是用“题目+自动化+评估+分析”这一套工程化的方法，像考试系统一样，持续保证大模型越来越好用、越来越可靠！

整体流程一图总结：



工程Harness是怎么实现的？

一文了解工程Harness到底是什么，看完这篇超越80%的人

北京 4月24日 14:54 已修改

