

给 AI 戴上六顶思考帽

原创 John AGI Hunt 2026年4月27日 12:01 北京



AGI Hunt

关注AGI 的沿途风景！ 前网易资深技术专家；出海某垂类 Agent 方向创业中；佛系写作
1815篇原创内容



公众号

我经常会在面试时间候选人：你平时用 Claude Code 或 Codex，最长会连续跑多久？

没用过的，或者少于一个小时的，我会默默给他减分。因为在我看来，能让 AI 来帮助自己完成长时间的任务，现在已经是必不可少的一项技能了。

我自己经常在想也是：**能不能用我尽可能少的指令和次数的输入，能得到 AI 更长时间的高质量输出？**

这里有两个关键词，一个是「长时间」，另一个是：


01

高质量

长时间其实不太难，用类似 ralph loop 的方式就能轻松做到。但高质量就没那么简单了，这好比强化学习中需要一个 Reward Model：模型能力再强，需要有靠谱的、无幻觉的奖励信号告诉它「什么算好」。

所以我现在的做法是：**在给 AI 下指令之前，会先把「如何检验任务是否完成」这个条件好不小的时间准备好。**

验证先行，且裁判和运动员尽可能隔离。然后就可以让 AI 在反复的迭代中，逼近目标。



四要素循环

这也属于是某种形式的 **Harness** 了：目标定义 + 验证接口 + 迭代协议 + 安全护栏，组合在一起后，就可能让 Agent 能连续跑几个小时甚至几天。


02

初版方案

我想，我应该把这个方案让更多人可以更简单的方式就能用上，从而轻松让自己的 AI 工作数小时之久，且能保证质量。

于是在跟 Claude Code 讨论了好几轮之后，得到了一份初版方案文档。

这个文档一共有 300 多行，把我喂它的两篇 Anthropic 博客的核心发现也梳理了一遍，对照了自己的 workflows，还设计了一个 `/harness` Skill 的完整框架。



初版草稿的局限

但说实话，这只是个比较初级的版本。它跟我自己的项目业务耦合得还是太紧了，同团队的人都不一定好用，更别说分享给其他人了。而且我看下来，里面也还是有不少欠考虑的地方。

于是我想把这个思路给团队的同学们 share 和讨论一下，听听他们的诉求和反馈，看能不能做得更通用一些。

03


交接 VS 协作

我之前做过一个叫 [cc-go-on](#) 的开源项目，能把 Claude Code 的会话加密导出，让别人不只是 show me the markdown，还能是 **show me the prompt** 来更好地了解 AI 协作的过程。



但说实话，cc-go-on 主要还是用来做干了一半的工作交接，查看、修改和协作方面，还是太欠缺了。

而上面说的事儿，大约是我月初时候的想法了。



正好这个周末有点时间，我想着要不再往前推一步。但用什么方式能和其他人更好地协作呢？怎么让 AI 能从不同的视角和出发点来 review、给我指指点点呢？


当然可以用各种 spec 工具，也可以搞一个 AI 团队来做这件事。但我个人习惯用的，还有一个比较重要的方法，叫做「六顶思考帽」。

04

六顶思考帽

这是 Edward de Bono 在 1985 年提出的思维方法：


六种颜色的「帽子」代表六种思维角色，强迫自己从完全不同的角度审视同一个问题。




蓝帽
流程主持




白帽
事实数据




红帽
直觉情感



黑帽
风险质疑



黄帽
收益价值



绿帽
创意替代

公众号 · AGHunt

六顶思考帽

白色看事实，红色看直觉，黑色挑毛病，黄色找价值，绿色想替代方案，蓝色负责主持收尾。

几年前，对于许多靠谱或不靠谱的想法，我都会用六顶思考帽进行分析，能让我对事情的判断更全面一些，只是……每次都分析一轮还挺费脑子的。

而现在都有 AI 了，那我显然更可以让 AI 来啊：

我需要 6 个 AI「同事」，各戴一顶帽子，同时看同一份草稿，然后各自输出判断，然后还可以喊人过来一起协作。

05

Moxt

我让 Claude Code 帮我来调研 AI 协作产品。我想的是，如果没有人把这事做好，那不行，或许我可以自己用一个周末来撸上一个。

不过我显然是高估了自己的创意，Claude Code 给了我一些项目和推荐理由，我分别点开看了下，最终锁定了一个叫 Moxt 的产品：




John's momo

Hi there 🌟 Your workspace is ready. Pick a file to get started, or just ask me anything.

Moxt 我有些印象，我记得在 X 上刷到过。Claude Code 对它的介绍是「The Agent-Native Workspace」，核心卖点是 AI Teammates：

你可以在一个工作空间里创建多个 AI 同事，每个有自己的名字、头像、角色定义、记忆，还有共享的文件空间。



Moxt 首页

而要说我为什么最终选了它……一开始也许，只是因为颜值吧。

而且它的 UI 和 UX 很能给我一种舒服感，完全不像我自己用 AI 整出来的钢铁 UI。当然最吸引我的，是「AI Teammates 共享 Team Space」这个设定，完全符合我的场景需求。


如果 6 个 AI 同事能共享同一份文件，那我只需要：

把草稿扔到共享空间 → 6 顶帽子各自去读 → 各自写评审 → 最好它们还能互相看对方写了什么。

06

搭舞台

在 Moxt 里创建 AI Teammate 的流程很简单：填个名字，写句描述，点 Create。



其中有一个细节是：每个 Teammate 创建后会自动做一轮 onboarding，去读工作空间里的 AGENTS.md（角色说明文件），然后主动问我「你希望我怎么沟通？我能做什么？」

像新员工入职先问几个问题，而不是冷启动给一个空白聊天框。

我一共创建了 6 个 Teammate，分别叫蓝帽、白帽、红帽、黑帽、黄帽、绿帽。

Moxt 自动给每个配了跟角色气质匹配的 emoji 头像：红帽是激情红脸，黑帽是严肃暗绿脸，黄帽竖着大拇指。



接下来，我把 harness_draft.md 上传到了 Team Space，让所有帽子 Agent 们都能读到这份草稿。

然后我给每顶帽子发了一份角色 brief。以蓝帽举例，发的是这样的：

“ 你是六顶思考帽中的蓝帽，负责流程主持和综合。先读 harness_draft.md，写一份评审议程，列出关键问题和发言顺序。等其他 5 顶帽子交了反馈后，写最终综合报告。所有内容用中文，输出到 Team Space。

每顶帽子收到 brief 后做的第一件事，都是去读 AGENTS.md，然后把自己的角色定义追加上去。

07

并行开工

蓝帽做为主持大局的人，它先是读了一遍草稿，然后写了一份《评审议程》：5 个关键问题、5 个争议点，以及其他帽子的发言顺序。



蓝帽写的评审议程

然后，其他的 5 顶帽子同时启动了。

而且是真的同时跑：6 个 chat 各跑各的，互不阻塞。并且 Moxt 里的 6 个 Teammate 各有各的聊天历史，各有各的角色记忆。



Team Space 全貌

这里更为重要的一点是：它们通过共享的 Team Space 文件来协作。

草稿就放在共享空间里，所有帽子都能读到。而它们写的评审输出也都回到共享空间，别的帽子同样看得到。

08

扎心的反馈

6 顶帽子最终交了 7 份文档（蓝帽出了两份：开头的议程和最后的综合）。全文太长了不适合人类阅读（适合 AI），有几个印象深刻的点：

红帽（直觉）的第一反应：

“ 我有一种「给还没出生的孩子写育儿手册」的感觉。所有东西都完整、工整，但我不确定它是从真实的疼痛里长出来的，还是从理论推演里画出来的。



红帽的评审

这句话属于还是，有点扎心了……

黑帽（风险）挑了个结构性的逻辑漏洞：

它发现我的草稿自己花了大量篇幅论证「模型自评会系统性偏高」，转头又在方案选择时说「单 Agent 自评够用了」。

“ 自评偏高的 Agent 恰恰无法发现自己在自评偏高。你不能指望一个系统性乐观的评审者告诉你「我太乐观了」。



黑帽的评审

这个矛盾我还真是完全没注意到。但凡你有过和 AI 多次交流后写文档的经验，你就会知道这种情况是非常常见的。

黄帽（收益）换了个角度看：

“厨具都有了。能部署、能查数据库、能操作浏览器、能跑测试。HARNESS.md 就是一份食谱，把这些现成的工具串成一条链就好。



黄帽的评审

绿帽（别误会……它负责的是创意）提了个我压根没想到的方向：

每个 HARNESS.md 跑完后，把「成功路径」提取为一份精炼的「经验卡」。下次遇到类似任务，先检索经验池来预填模板。

越跑越多，经验池越丰富，新 Harness 质量越高，又产出更好的经验卡。



绿帽的评审

这不就是自我进化了吗，真的还得是 AI，比我想的更 AI.....

我的初版里压根没想到这一层。

最后，蓝帽做了最终综合：

11 条具体修改建议，3 个需要我拍板的分歧点，8 个按优先级排序的 TODO。



蓝帽综合报告

其中有一条建议我特别认同：草稿的定位应该从「调研报告」转为「试点计划」。

红帽说了，有理论有结构有模板，但没有故事。那就去跑一个真实任务，让案例本身成为故

事。

09

文件即协作


后面更细的评审内容，和我们后续的交互，我就不过多展示了……因为这是一个没完成的真项目。

而且我还需要进一步打磨，还得找更多人来协作和验证，现在放出来为时尚早。我也考虑到这是周末，还没发给其他人来评审，拉上真人们来和 AI 们一起协作。

不过，在整个 Moxt 的使用过程中值得我关注的，倒不是哪顶帽子说了什么惊人的话，而是 **6 个 Agent 之间确实在实时通过文件协作**。

黑帽挑毛病的时候，引用了白帽验证过的事实：「白帽已确认该项目实际主语言是 Shell 和 Go」。

蓝帽做综合的时候，标注了每条建议的出处：「综合黑帽结构性盲区质疑 + 绿帽 AI 同事作为 Evaluator 创意 + 黄帽低成本启动原则」。



六顶帽子通过 Team Space 协作

它们并非各写各的，而是在实时读取对方的产出，然后在自己的输出里引用、回应、反驳。

这才是 Workspace 的意义：给一组 AI 一张共享的工作台，而不只是一个聊天窗口。

真有点传统办公室里我们用飞书文档的感觉了。

Moxt 跟飞书 AI 伙伴的区别，也正在于此：飞书的 AI 伙伴是一个通用 AI，你问什么它答什么。Moxt 的 AI Teammates 是多个独立个体，通过文件产生关系。

打个可能不太恰当的比方，飞书 AI 像一个全能助理。而 Moxt 更像一间办公室，里面坐着几个人（AI），桌上放着共享文件夹，每个人翻完后在上面写自己的批注。

10


几个小问题

不过 Moxt 也有些使用上的小问题。

不能回滚：我第一次给帽子发 brief 的时候，本来想写多行文字，结果不小心敲了个回车（应该用 Shift+Enter 换行），结果就直接发送了。虽然可以中止，但我没找到怎么取消重来。

CLI 没有 API Key 入口：我让 Claude Code 找到 Moxt 有个 CLI 工具（`@moxt-ai/cli`），用它需要 API Key，但在它的网站里找不到这个 Key 在哪，不知道是我不会找，还是光做了个工具……但钥匙没配好（我推测是正在开发快上线，没想到被我的 AI 找到了）。

早期小问题



Enter 误发与 CLI 钥匙


前一个还好不太碍事，后一个有点不太符合我爱在终端里用的习惯……

零摩擦

Moxt 联创张昊然在其[公众号文章](#)中，提到了一个概念：**零摩擦**。

AI 处理信息的速率太快、带宽太大，哪怕只有 1% 的非原生损耗，在复杂任务的 n 次操作后也会被指数级放大。

所以 Moxt 把所有内容都转成了 .md、.csv、.html 这些 AI 原生的格式，知识组织用的是文件系统的目录结构。



AI 原生格式 vs 传统格式

回头看我这次为什么六顶思考帽能跑得通，也正是因为 AI 读写的就是最原生的 Markdown，存放在它们完全理解的目录里，所以才能更好的互相引用和回应。

Moxt 看起来还很早期，功能也在完善中。它的方向是：**给 AI 一个真正适合它们工作的环境，而不只是在旧工具上加个聊天框。**

不过在我看来，AI 的评审当然不能替代人的判断。

但它更好的帮我把「多角度审视」的时间成本和多人协作的沟通成本进行了压缩。

而这些省下来的时间，应该花在真正需要人的判断力的地方去。



Moxt: <https://moxt.ai>



[阅读原文](#)